Marcelo Fernandes de Oliveira Junior
Gustavo Oliveira dos Santos
Christian Lima Santana

Análise Comparativa de Desempenho e Eficiência Energética entre Processamento de OCR em Borda e em Nuvem aplicado à Smart Metering.

São Paulo
2026

Marcelo Fernandes de Oliveira Junior
Gustavo Oliveira dos Santos
Christian Lima Santana

Análise Comparativa de Desempenho e Eficiência Energética entre Processamento de OCR em Borda e em Nuvem aplicado à Smart Metering.

Trabalho de Conclusão de Curso II apresentado ao SENAC Santo Amaro como requisito parcial para conclusão do curso de Bacharelado em Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Bacharelado em Ciência da Computação

Orientador: Afonso César Lelis Brandão

São Paulo
2026

Resumo

Este trabalho busca propor uma análise comparativa entre dois métodos de processamento para sistemas de Smart Metering (medição inteligente): Edge Computing (Computação em Borda), com inferência de Optical Character Recognition (OCR) realizada localmente no microcontrolador ESP32-CAM por meio de modelo de aprendizado de máquina treinado de forma supervisionada e quantizado em inteiros de 8 bits, e Cloud Computing (Computação em Nuvem), com inferência realizada em ambiente remoto através de modelo treinado de forma supervisionada e quantizado em ponto flutuante de 32 bits. A motivação reside no elevado custo de substituição dos mais diversos medidores convencionais, amplamente utilizados em ambientes residenciais e privados, por modelos inteligentes nativos, o que favorece o *retrofitting* como alternativa mais economicamente viável. A transmissão dos dados entre os nós de borda e o gateway central é realizada via rede Long Range Wide Area Network (LoRaWan), utilizando o Spreading Factor SF8, configuração que assegura conformidade com o limite regulatório de *dwell time* de 400 ms estabelecido pelo Ato nº 14.448 da ANATEL, ao mesmo tempo em que maximiza o alcance dentro desse limite. A viabilidade do envio de imagens fragmentadas via LoRaWan foi demonstrada analiticamente, com uma imagem de 160×120 pixels em escala de cinza, comprimida utilizando o algoritmo JPEG com aproximadamente 3,10 KB, podendo ser transmitida em 38 pacotes em cerca de 13,3 s de rádio ativo. Os dois fluxos de processamento serão avaliados segundo três métricas quantitativas: acurácia de leitura OCR (%), latência de ponta a ponta (ms) e consumo energético por leitura (mAh). O objetivo deste trabalho é apresentar resultados que orientem a escolha arquitetural mais adequada para implantações de *Smart Metering* em larga escala, considerando o *trade-off* entre eficiência energética, precisão de reconhecimento e complexidade de manutenção do sistema.

Palavras-chave: Smart Metering. ESP32. LoRaWan. OCR.

Abstract

This work aims to propose a comparative analysis between two processing methods for Smart Metering systems: Edge Computing, with OCR inference performed locally on the ESP32-CAM microcontroller using a machine learning model trained in a supervised manner and quantized to 8-bit integers, and Cloud Computing, with inference performed in a remote environment through a model trained in a supervised manner and quantized to 32-bit floating point. The motivation lies in the high replacement cost of the most diverse conventional meters, widely used in residential and private environments, by native smart models. This favors *retrofitting* as a more economically viable alternative. Data transmission between the edge nodes and the central gateway is carried out via a LoRaWan network, using Spreading Factor SF8, a configuration that ensures compliance with the dwell time regulatory limit of 400 ms established by ANATEL Act No. 14.448, while maximizing range within that limit. The feasibility of sending fragmented images via LoRaWan was demonstrated analytically, with a 160×120 pixel grayscale image, compressed using the JPEG algorithm to approximately 3.10 KB, which can be transmitted in 38 packets in about 13.3 s of active radio time. The two processing flows will be evaluated according to three quantitative metrics: OCR reading accuracy (%), end-to-end latency (ms), energy consumption per reading (mAh). The objective of this work is to present results that guide the most appropriate architectural choice for large-scale *Smart Metering* deployments, considering the *trade-off* between energy efficiency, recognition precision, and system maintenance complexity. **Keywords**: Smart Metering. ESP32. LoRaWan. OCR.

Lista de ilustrações

Figura 1 – Campos contidos em um pacote de Uplink 16
Figura 2 – Campos contidos em Frame Header em Downlink 16
Figura 3 – Pilha de elementos das camadas LoRa/LoRaWan 18
Figura 4 – Implementação Típica de Rede LoRaWan 18
Figura 5 – Módulo ESP32-CAM integrado com LoRa 20
Figura 6 – Distribuição de Trabalhos Relacionados à Computação em IoT 22
Figura 7 – Exemplo de inserção de figura — substitua pelo diagrama da arquitetura da sua solução. 37

Lista de tabelas

Tabela 1 – Strings de busca utilizadas no levantamento bibliográfico. 14
Tabela 2 – Classes de Configuração LoRa 15
Tabela 3 – Parâmetros de Configuração LoRa 17
Tabela 4 – Vantagens e Desvantagens na Adoção de Métodos de Processamento . 23
Tabela 5 – Uplink: Canais de Frequência 24
Tabela 6 – Downlink: Canais de Frequência 24
Tabela 7 – Taxas de transmissão Uplink e configurações LoRaWAN. 25
Tabela 8 – Parâmetros de Downlink Data Rate 26
Tabela 9 – Downlink RX1 Data Rate Mapping 27
Tabela 10 – Comparação de métricas reportadas 38

Lista de Abreviaturas e Siglas

ABP Activation by Personalization 19

BW Bandwidth 17

CNN Convolutional Neural Network 29, 32

CR Coding Rate 17

CRNN Convolutional Recurrent Neural Network 32

CSS Chirp Spread Spectrum 25

CTC Connectionist Temporal Classification 32

DR Data Rate 25, 26

EIRP Effective Isotropic Radiated Power 27

IA Inteligência Artificial 27, 28

IaaS Infrastructure as a Service 22

IoT Internet of Things 10–13, 18, 21, 22

ISM Industrial, Scientific and Medical 23, 24

LoRa Long Range 11, 13, 15, 25, 27, 35

LoRaWan Long Range Wide Area Network 2, 3, 12–15, 17, 18, 33, 34, 36

LPWAN Low Power Wide Area Network 17

LR-FHSS Long Range Frequency Hopping Spread Spectrum 25

OCR Optical Character Recognition 2, 3, 11, 12, 27, 31, 33, 35, 36

OTAA Over the Air Activation 19

PDR Packet Delivery Ratio 36

QAT Quantization-Aware Training 31

RGB Red, Green, Blue 29

RNA Redes Neurais Artificiais 30

RNN Recurrent Neural Network 32

SaaS Software as a Service 22

SF Spreading Factor 17, 25

Sumário

1 INTRODUÇÃO . . . 10
1.1 Contextualização do problema . . . 10
1.2 Formulação do problema . . . 11
1.3 Objetivos e hipótese . . . 11
1.3.1 Objetivo geral . . . 11
1.3.2 Objetivos específicos . . . 12
1.3.3 Hipótese . . . 12
1.4 Justificativa . . . 12

2 REVISÃO BIBLIOGRÁFICA / TRABALHOS RELACIONADOS . . 14
2.1 Metodologia da pesquisa bibliográfica . . . 14
2.2 Fundamentos teóricos . . . 15
2.2.1 LoRa . . . 15
2.2.2 LoRaWan . . . 17
2.2.2.1 Dispositivos Finais (End Nodes) . . . 18
2.2.2.2 Gateways . . . 20
2.2.2.3 Servidores de Rede e Aplicação . . . 21
2.2.3 Edge Computing e Cloud Computing . . . 22
2.2.4 Restrições Regulatórias . . . 23
2.2.5 Inteligência Artificial . . . 27
2.2.5.1 Machine Learning . . . 27
2.2.5.1.1 Aprendizado Supervisionado . . . 28
2.2.5.2 Deep Learning . . . 28
2.2.5.3 Redes Neurais . . . 28
2.2.5.3.1 Redes Neurais Convolucionais . . . 28
2.2.5.3.2 Camadas que Constituem uma CNN . . . 29
2.2.5.3.3 Camada Convolucional . . . 29
2.2.5.3.4 Camada de Pooling . . . 29
2.2.5.3.5 Camada Totalmente Conectada . . . 30
2.2.5.3.6 Arquitetura U-Net . . . 30
2.2.5.4 Quantização e QAT . . . 30
2.2.5.5 OCR - Fundamentos e Escopo . . . 31
2.2.5.5.1 Pipeline Tradicional . . . 31
2.2.5.5.2 Evolução Tecnológica: dos Métodos Heurísticos ao Deep Learning . . . 31
2.2.5.6 Arquitetura CRNN e CTC . . . 32

2.3 Trabalhos correlatos . . . 33
2.3.1 Trabalho 1: Solução IoT para Digitalização de Medidores de Consumo por Visão Computacional e MicroML . . . 33
2.3.2 Trabalho 2: Sistema de Gerenciamento Inteligente de Água Utilizando Sensores Baseados em IoT . . . 34
2.3.3 Trabalho 3: Rede de Sensores Sem Fio Habilitada para LoRa para Leitura e Faturamento de Consumo de Água Usando Reconhecimento Óptico de Caracteres . . . 35

3 DESENVOLVIMENTO / IMPLEMENTAÇÃO / EXPERIMENTOS 36
3.1 Metodologia da pesquisa . . . 36
3.1.1 Desempenho da Rede de Comunicação . . . 36
3.1.2 Acurácia da Visão Computacional (OCR) . . . 36
3.1.3 Autonomia Energética . . . 37
3.2 Detalhes da implementação . . . 37
3.3 Experimentos e cenário de testes (opcional) . . . 37
3.4 Resultados e análises . . . 38

4 CONCLUSÃO . . . 39
4.1 Retomada do problema e dos objetivos . . . 39
4.2 Contribuições para a Computação . . . 39
4.3 Limitações e trabalhos futuros . . . 39

Observações importantes . . . 40

Apresentação oral (banca) . . . 41

REFERÊNCIAS . . . 43

1 Introdução

Atualmente, a implantação de conceitos de Internet of Things (IoT) nos mais diferentes dispositivos presentes no dia a dia de milhões de pessoas ao redor do mundo está numa crescente jamais antes vista. Como explicado por Tedjojuwono e Jahja (2024), a adoção de dispositivos IoT é um dos principais pilares na ascensão da indústria 4.0, principalmente na pauta da construção de cidades inteligentes. E ainda, por característica, tais tecnologias viabilizam a coleta de dados de forma constante, promovendo insumos para realização de análises, manutenções e aprimoramentos de sistemas através de planos de ação mais eficientes e eficazes.

Em contrapartida, como explicado por Fortune Business Insights (2025) e Uggeri e Simeon (2020), o alto custo inicial exigido para realizar a transição de dispositivos analógicos para soluções inteligentes nativas constitui o principal entrave para a adoção de tais tecnologias em larga escala. A complexidade de infraestrutura necessária para a substituição física dos medidores limita a viabilidade econômica de projetos em áreas privadas de pequeno e médio porte.

Abordando a pauta de automação residencial e comercial, o tema de smart metering surge como ponto focal na discussão. Como evidenciado pelo contraste em abordagens de Vilela (2021) e Adam (2022), o desenvolvimento de sistemas focados em smart metering enfrenta um impasse arquitetônico, onde o método de processamento divergia entre os projetos.

A implementação proposta por Vilela (2021) é a denominada Edge Computing, onde o processamento é realizado localmente no dispositivo final, assim otimizando recursos energéticos e latência. Em oposição, a proposta de Adam (2022), realizando processamento em cloud (Cloud Computing), surge como uma solução focada em facilidade de manutenção, utilização de softwares mais robustos e menor complexidade de implementação.

Neste contexto, a finalidade deste trabalho é realizar a comparação entre os métodos de processamento citados, definindo limites, vantagens e desvantagens sob determinado ambiente.

1.1 Contextualização do problema

O mundo, neste momento, está passando pelo que pode ser chamado de era da digitalização, havendo severas transformações no modo de transmissão de dados e informações (TEDJOJUWONO; JAHJA, 2024). Atualmente, a humanidade encontra-se sob influência da expansão da denominada indústria 4.0, que tem como foco a digitalização dos processos de manufatura e produção, mas que engloba inclusive o modo de vida e acesso a informações da sociedade sob o braço tecnológico denominado *Cidades Inteligentes*.

Neste contexto, a utilização de hardware inteligente deixou de ser mero luxo de grandes corporações para se tornar o paradigma central na mudança citada anteriormente. Em relação a equipamentos de medição inteligentes, também classificados como Smart Metering, hoje já há uma série de avanços que possibilitam o processamento de dados de maneira mais veloz e eficiente. Mas essa evolução também acompanhou a necessidade de adaptação de infraestrutura, assim agregando altos custos para a transição das tecnologias analógicas para o digital (ALVISI et al., 2019).

Como apresentado por Alvisi et al. (2019), o retrofitting é uma das soluções mais difundidas para contornar o alto custo de digitalização de sistemas nativamente analógicos. Tal conceito tem como objetivo realizar a digitalização de sistemas analógicos reaproveitando o hardware já existente. Essa concepção é amplamente abordada na academia, havendo grandes teses, trabalhos e dissertações sobre o tema.

Diante de tal abordagem para redução de custos, a aplicabilidade da técnica de retrofitting enfrenta um impasse. Atualmente, na academia encontram-se mais difundidos trabalhos que abordam o uso de microcontroladores aliados à tecnologia Long Range (LoRa) utilizando o método de processamento em borda. Como explicado por Vilela (2021), a utilização deste método traz grandes vantagens em relação à latência e otimização de consumo energético. Em oposição, como Andriulo et al. (2024) apresenta, o método de processamento em cloud destaca-se por proporcionar maior granularidade de dados, simplificação no desenvolvimento de firmware e acurácia ligeiramente melhor em relação ao conceito de Edge Computing. Todavia, permanece a dúvida de qual método de processamento utilizar no desenvolvimento de uma solução IoT baseada na técnica de retrofitting. A resolução do problema criará um alicerce, auxiliando o desenvolvimento de futuras ferramentas que, por concepção, apresentarão a mesma natureza de problemática.

1.2 Formulação do problema

Coloque o problema em forma de pergunta clara, delimitando o que será investigado e qual resultado se espera atingir dentro da Computação. A pergunta de pesquisa deve ser específica o suficiente para ser respondida ao longo do trabalho e diretamente derivada da lacuna apresentada na contextualização.

1.3 Objetivos e hipótese

1.3.1 Objetivo geral

Comparar a viabilidade técnica, a acurácia e o consumo energético entre o processamento de OCR realizado localmente no ESP32-CAM (abordagem Edge Computing) e a inferência

OCR realizada remotamente em servidor na nuvem (Cloud), utilizando a rede LoRaWan como meio de transmissão.

1.3.2 Objetivos específicos

1. Implementar os dois fluxos de processamento que compõem o experimento comparativo: o fluxo Edge, em que o OCR ocorre localmente no ESP32-CAM; e o fluxo Cloud, em que a imagem é transmitida para processamento remoto;

2. Configurar a rede LoRaWan conectando os nós da rede com o objetivo de reduzir ao máximo o consumo energético;

3. Avaliar e comparar os dois fluxos segundo as métricas: precisão de leitura (%), latência de processamento (ms), consumo energético por leitura (mAh) e volume de dados transmitidos (bytes/leitura), identificando o *trade-off* entre processamento local e transmissão.

1.3.3 Hipótese

Considerando o trade-off apresentado, foram estabelecidas hipóteses com o objetivo de verificar se a utilização de determinada abordagem apresenta vantagens quando observadas sob o mesmo cenário. As hipóteses orientam a definição dos experimentos e a análise dos resultados obtidos.

- **H1**: A quantização em inteiros de 8 bits, aplicada ao modelo implementado no fluxo de processamento em borda, causa redução de acurácia em comparação ao modelo quantizado em ponto flutuante de 32 bits, implementado no fluxo de processamento em nuvem.

- **H2**: O método de processamento local apresenta menor latência e maior valor de taxa de pacotes entregues, em comparação com o método de processamento remoto.

- **H3**: A abordagem de processamento em nuvem apresenta autonomia energética inferior durante a transmissão de mensagens quando comparada ao método de processamento local.

1.4 Justificativa

Este trabalho propõe uma abordagem analítica sobre métodos de processamento implementados em sistemas baseados em tecnologias IoT com o objetivo de aplicação da técnica de retrofitting em instrumentos de medição analógicos. Tal temática tem como alicerce a lacuna literária identificada por Andriulo et al. (2024), na qual carecem trabalhos

que apresentam informações úteis para a etapa de desenvolvimento arquitetural de tais ferramentas.

Diante de tal contexto, revela-se a importância acadêmica deste trabalho, apresentando de forma científica comparações entre os métodos de processamento, definindo limites e estipulando vantagens na adoção de determinado método. E ainda, este trabalho tem como pauta discorrer sobre os temas: desenvolvimento de sistemas baseados em tecnologia LoRa, aplicação de algoritmos de packet loss (perda de pacotes) e uplink de dados segmentados em pacotes via LoRaWan.

O desenvolvimento deste trabalho tem por foco a disponibilização de insumos para tomada de decisões no desenvolvimento de sistemas IoT que empregam protocolos de rede de baixa largura de banda.

2 Revisão Bibliográfica / Trabalhos Relacionados

A revisão bibliográfica tem como finalidade apresentar o embasamento teórico do trabalho, demonstrando o conhecimento do autor sobre o tema e identificando o estado da arte. Este capítulo está organizado em três seções: a **metodologia da pesquisa bibliográfica** (como as fontes foram levantadas e selecionadas), os **fundamentos teóricos** (os conceitos, teorias e técnicas que fundamentam a proposta) e os **trabalhos correlatos** (estudos que enfrentaram o mesmo problema, com suas limitações).

2.1 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi conduzida de forma sistemática, estruturando-se em três temas principais: Hardware, Software e Redes. Para a seleção dos trabalhos, utilizaram-se as bases de dados Google Scholar, MDPI e Intechopen.

O processo de seleção seguiu um fluxo de filtragem (funil). Inicialmente, foram identificados 120 artigos por meio da análise de títulos, utilizando strings de busca majoritariamente em inglês, tais como “iot AND energy efficiency” e “ESP32 AND camera monitoring”. Como ferramentas auxiliares na descoberta de conexões entre autores e na triagem inicial de relevância, foram utilizadas as plataformas ResearchRabbit e Gemini Deep Research.

Na etapa de refinamento, aplicou-se a leitura dos resumos (abstracts) e a verificação de disponibilidade integral dos textos. Foram adotados como critérios de inclusão: artigos publicados entre 2020 e 2026, relevância direta para sistemas de telemetria e foco em implementações práticas. Como critério de exclusão, descartaram-se trabalhos com acesso restrito ou que não apresentassem detalhes técnicos sobre a integração dos eixos propostos.

Tabela 1 – Strings de busca utilizadas no levantamento bibliográfico.

ID	Eixo Temático	String de Busca
ST01	Redes	"IoT"AND "LoRaWan"AND "water waste"
ST02	Contexto	smart water meter market
ST03	Contexto	smart water meter costs and benefits
ST04	Hardware	"IoT"AND "energy efficiency"
ST05	Hardware	"ESP32"AND "camera monitoring"
ST06	Hardware	"ESP32-CAM"AND "analog meter"AND "OCR"
ST08	Software	"automatic meter reading"OCR accuracy "error rate"evaluation
ST09	Redes	"packet delivery ratio"LoRaWan "latency"monitoring system
ST010	Contexto	"water consumption predictionmean absolute error"forecasting metrics

2.2 Fundamentos teóricos

2.2.1 LoRa

Como explicado por Pastório et al. (2022), LoRa é uma tecnologia, patenteada e desenvolvida pela Semtech, que tem como foco viabilizar a transmissão de dados sem fio em longo alcance através de radiofrequência.

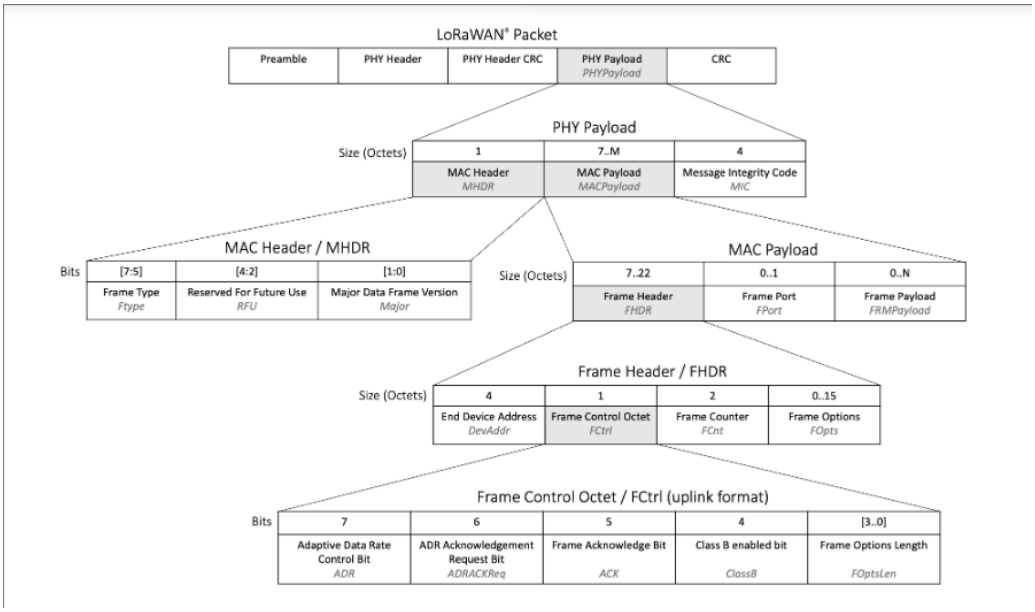
A rede LoRaWan é constituída por dispositivos finais, gateways e servidores de rede/aplicação. Com o objetivo de realizar um gerenciamento mais fino de consumo energético, a comunicação entre os dispositivos finais e servidores de rede é definida por três classes como demonstrado na tabela 2.

Tabela 2 – Classes de Configuração LoRa

Classe	**Descrição**	**Característica**
Classe A	O dispositivo final é habilitado a receber downlink imediatamente após ser realizado um envio de mensagem (uplink).	Menor consumo energético e menor tráfego de mensagens.
Classe B	O dispositivo final é habilitado a receber downlink em períodos agendados e conhecidos.	Consumo energético significativamente maior que a classe A, mas viabiliza comunicação mais frequente entre servidor e dispositivo final.
Classe C	O dispositivo final é continuamente habilitado a receber downlink.	Consumo energético muito alto, mas viabiliza a comunicação entre as partes de forma quase ininterrupta.

Fonte: Adaptado de Semtech Corporation (Semtech Corporation, 2024b).

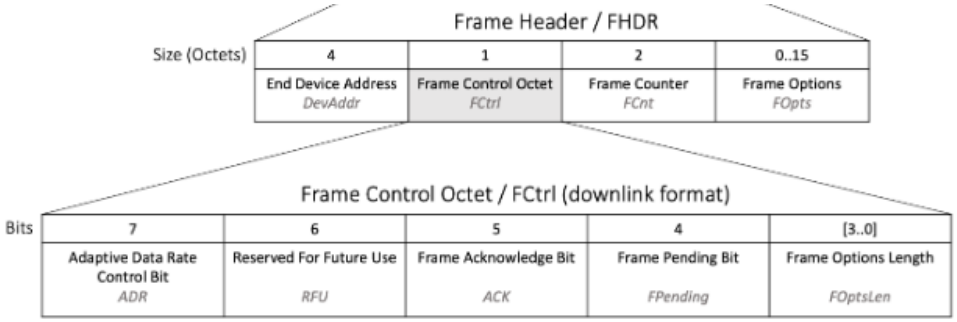
Figura 1 – Campos contidos em um pacote de Uplink



Fonte: Adaptado de Semtech Corporation (Semtech Corporation, 2024c).

A figura 1 apresenta a estrutura de pacote de rede que é utilizada na tecnologia LoRa. Tal estrutura é utilizada tanto no envio de dados pelo dispositivo final (uplink) quanto no recebimento de dados (downlink).

Figura 2 – Campos contidos em Frame Header em Downlink



Fonte: Adaptado de Semtech Corporation (Semtech Corporation, 2024c).

A estrutura do pacote de rede de uplink e downlink é a mesma, mas há diferenças em flags específicas entre os tipos de transmissão de dados. A figura 2 apresenta a estrutura do "Frame Header / FHDR" utilizada em downlink. As estruturas de pacote divergem na flag de classe B, no uplink, por meio da qual o dispositivo final informa ao servidor estar no modo de recebimento de mensagens em tempo programado, e, no pacote downlink, na flag FPending, utilizada para informar a existência de mais mensagens a serem enviadas pelo servidor/gateway.

Conforme apresentado pela LoRa Alliance Regional Parameters Workgroup (2025) o tamanho máximo de MACPayload, respeitando o padrão regulatório AU915, que será mais bem explicado e abordado posteriormente, em bytes, é variável e dependente do tamanho ocupado pelo atributo Fopts, que é utilizado para solicitar alterações de parâmetros de rede ao dispositivo final. Não utilizando repetidores de sinal que interligam dispositivos finais com gateways, o tamanho máximo de MACPayload é de 250 bytes, restando em torno de 227 bytes utilizáveis em payload.

Para viabilizar a modulação LoRa em dispositivo final, é necessário realizar a configuração de três parâmetros fundamentais. A tabela 3 apresenta as definições dos principais parâmetros que ajustam o funcionamento da rede LoRaWan.

Tabela 3 – Parâmetros de Configuração LoRa

Parâmetro	**Definição**
Bandwidth (BW)	Determina a capacidade máxima de transmissão em determinado período de tempo (medido em kHz).
Spreading Factor (SF)	Determina o alcance do sinal de rádio; o SF é determinado por classes, nas quais, quanto maior a classe, maior a área de alcance do sinal.
Coding Rate (CR)	Número de bits destinados à redundância de dados, utilizado para possibilitar recuperação da mensagem em caso de erros na transmissão.

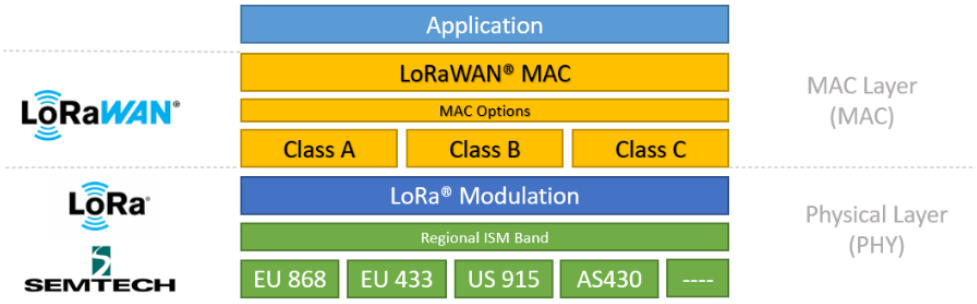
Fonte: Adaptado de Pastório et al. (2022).

2.2.2 LoRaWan

O LoRaWan é um protocolo de comunicação baseado na tecnologia Low Power Wide Area Network (LPWAN), que possui o objetivo de viabilizar a comunicação em grandes distâncias, conciliada ao baixo consumo energético. O protocolo é open-source e mantido pela LoRa Alliance. Como citado anteriormente, a rede LoRaWan é formada por dispositivos finais, gateways, servidores de rede e servidores de aplicação (PASTóRIO et al., 2022).

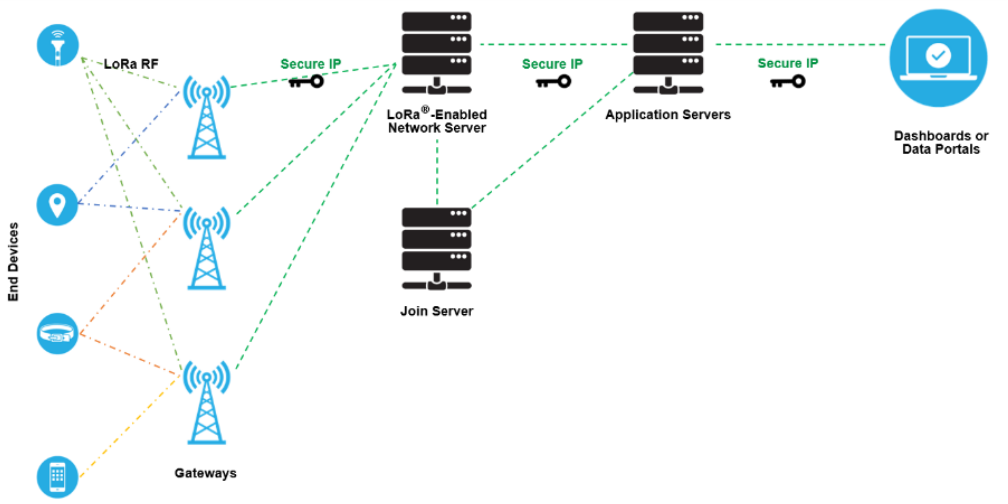
A figura 3 apresenta a pilha de elementos das camadas MAC e Física que compõem a arquitetura do protocolo LoRaWan.

Figura 3 – Pilha de elementos das camadas LoRa/LoRaWan



Fonte: Adaptado de Semtech Corporation (Semtech Corporation, 2024a).

Figura 4 – Implementação Típica de Rede LoRaWan



Fonte: Adaptado de Semtech Corporation (Semtech Corporation, 2024a).

A figura 4 apresenta a arquitetura típica de um sistema IoT que utiliza como base o protocolo LoRaWan para viabilizar a comunicação entre os dispositivos. Cada elemento que compõe uma rede LoRaWan possui uma responsabilidade; neste momento, é extremamente válido analisá-las individualmente:

2.2.2.1 Dispositivos Finais (End Nodes)

Semtech Corporation (2024a) define que dispositivos finais habilitados para LoRaWan são sensores ou atuadores que são conectados a gateways via modulação de radiofrequência LoRa.

Na maioria das aplicações, esses dispositivos são autônomos, dependentes de baterias como fonte energética primária e possuem como responsabilidade digitalizar condições físicas como temperatura, captura de imagens, níveis de tremulação, entre outros.

Em relação às possíveis configurações que podem ser aplicadas nos dispositivos finais, como apresentado por Pastório et al. (2022), cada nó pode assumir uma das configurações que a tabela 2 apresenta. Outro parâmetro configurável é o tipo de autenticação dos dispositivos em rede, havendo o padrão Over the Air Activation (OTAA), no qual o próprio dispositivo gerencia a conexão à rede, e a Activation by Personalization (ABP), na qual os dispositivos são vinculados de forma manual a uma rede em específico, não passando pelo processo de entrada implementado no OTAA.

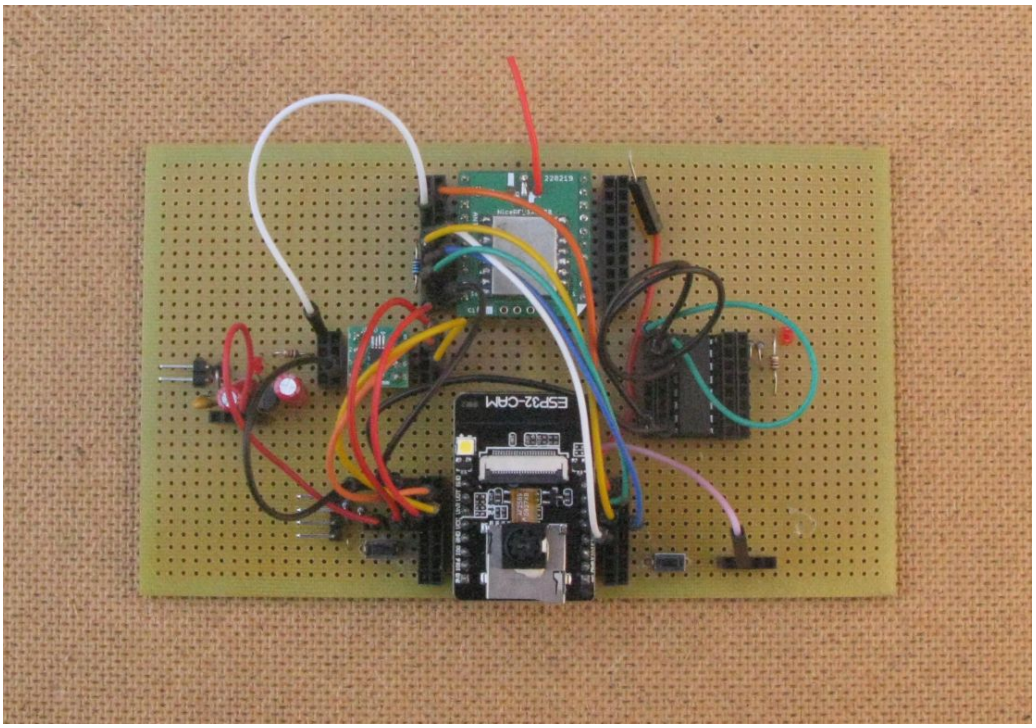
O LoRaWan utiliza o padrão AES de criptografia simétrica, aplicado tanto na camada de aplicação quanto na camada de rede.

Os dispositivos finais, corriqueiramente, são desenvolvidos sobre microprocessadores, podendo tanto utilizar placas que já incluem módulos LoRaWan nativos quanto serem desenvolvidos sobre plataformas como ESP32, Arduino, Raspberry Pi, entre outras. A partir da construção do dispositivo, ou acoplamento de módulos, possibilita-se a captura de dados em ambiente (PASTóRIO et al., 2022).

Como destacado por Sari et al. (2022) e Ahmad et al. (2021), o ESP32 destaca-se nesse cenário como uma plataforma robusta de baixo custo, integrando conectividade sem fio e múltiplos modos de operação. Diferentemente de arquiteturas mais simples, o ESP32 permite a execução de tarefas complexas e segurança criptográfica sem comprometer severamente o ciclo de vida da bateria, desde que devidamente configurado.

Segundo Ferreira e Cavalcante (2020), a vida útil da bateria é influenciada criticamente não apenas pelo hardware, mas pela eficiência das rotinas de escrita em periféricos e pela otimização do firmware. Diante de tal afirmação, destaca-se a função *deep sleep* presente no ESP32 que possui como foco a minimização do consumo energético quando em estado ocioso.

Figura 5 – Módulo ESP32-CAM integrado com LoRa



Fonte: (ROBINSON, 2021).

2.2.2.2 Gateways

O gateway, como demonstrado na figura 4, é um elemento da rede LoRaWan que tem como responsabilidade agrupar dispositivos finais e viabilizar a comunicação entre o dispositivo final e o servidor de rede (PASTóRIO et al., 2022).

A comunicação entre o dispositivo final e o gateway é realizada via protocolo LoRaWan, na qual o gateway pode realizar a tarefa de registrar tráfego de mensagens. Como explicado por Semtech Corporation (2024a), os dispositivos finais, ao realizar o envio de uplink, distribuem as suas mensagens a todos os gateways alcançáveis dentro da mesma rede; tal função tem como objetivo garantir que ao menos um dos gateways da rede receba e transmita a mensagem ao servidor de rede.

Os gateways operam na camada física e, convencionalmente, assumem a responsabilidade apenas de viabilizar o tráfego de requisições uplink e downlink e realizar a verificação de integridade do pacote, não realizando processamento intermediário da mensagem para enviá-la ao servidor de rede (Semtech Corporation, 2024a).

A comunicação entre o gateway e o servidor de rede, corriqueiramente, é estabelecida utilizando protocolo TCP/IP. Toda comunicação dentro do protocolo LoRaWan é bidirecional (PASTóRIO et al., 2022).

É possível encontrar gateways prontos de múltiplos canais sendo comercializados, mas é plenamente viável desenvolver gateways a partir de módulos e placas de prototipagem

como a apresentada na figura 5.

2.2.2.3 Servidores de Rede e Aplicação

Como apresentado por Pastório et al. (2022), servidores de rede e servidores de aplicação, dada a estrutura em que foram desenvolvidos, tanto podem ser implementados sob o mesmo hardware, como podem estar fisicamente distantes, realizando comunicação através de protocolo TCP/IP.

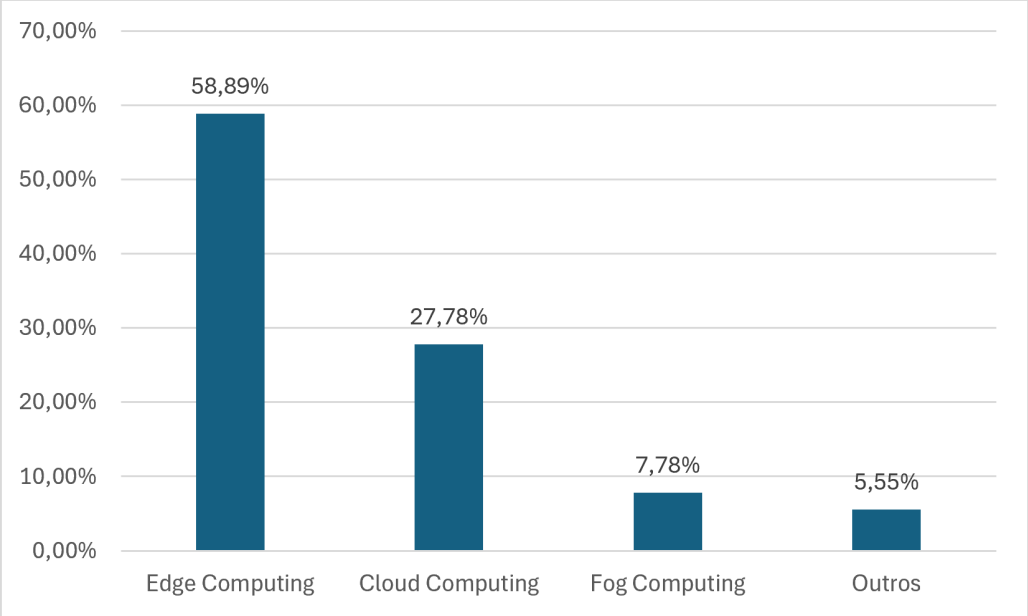
Como explicado pela Semtech Corporation (2024a), servidores de rede são responsáveis por gerenciar dinamicamente a rede de dispositivos, adaptando o sistema para se ajustar a um cenário de constante mudança de parâmetros. Entre as responsabilidades dos servidores de rede estão: receber, descartar duplicatas e descriptografar mensagens enviadas por uplink, realizar autenticação, garantir segurança com o protocolo AES, confirmar recebimento de mensagens, responder a requisições de camada MAC, realizar configuração de dispositivos finais através de requisições downlink, entre outras.

Servidores de Aplicação, por sua vez, são responsáveis por receber pacotes enviados pelo servidor de rede, tratar e disponibilizar em formato de informação ao usuário os dados extraídos pelos dispositivos finais. Como a Semtech Corporation (2024a) explica, é uma de suas responsabilidades também gerenciar os payloads de downlink a serem enviados aos dispositivos finais.

Ambos os tipos de servidores possuem diversas soluções prontas para implementação tanto em ambiente local quanto em nuvem. Para servidores de rede, destaca-se o Chirp Stack, que tem por foco o gerenciamento de dispositivos de IoT em rede privada. Já para servidores de aplicação, o Tago IO mostra-se como uma ferramenta robusta, com foco corporativo e ampla gama de ferramentas voltadas para gerenciamento de dispositivos (PASTóRIO et al., 2022).

2.2.3 Edge Computing e Cloud Computing

Figura 6 – Distribuição de Trabalhos Relacionados à Computação em IoT



Fonte: Adaptado de Andriulo et al. (2024).

Edge Computing (computação em borda), em IoT, é uma arquitetura baseada em processamento descentralizado de dados, na qual ocorre o processamento com o objetivo de construção de informações a partir de dispositivos que têm por responsabilidade inicial a extração de dados do ambiente real. Como explicado por Andriulo et al. (2024), o gráfico apresentado na figura 6 demonstra que Edge Computing é a abordagem mais amplamente difundida na literatura, sendo uma solução voltada à segurança de informações e à otimização de redes de baixa largura de banda, promovendo possível redução de custos operacionais.

Cloud Computing (computação em nuvem), ainda no ambiente IoT, é um tipo de arquitetura pautado pela alta escalabilidade de armazenamento de dados e poder computacional centralizado ou não. Como explicado também por Andriulo et al. (2024), este tipo de arquitetura tem como prós a possível adoção de provedores de nuvem, acoplando serviços como Infrastructure as a Service (IaaS), Software as a Service (SaaS), entre outros, assim reduzindo investimentos iniciais, apresentando maior facilidade de manutenção sistêmica e menor complexidade no desenvolvimento de firmware.

Tabela 4 – Vantagens e Desvantagens na Adoção de Métodos de Processamento

Método	**Vantagens**	**Desvantagens**
Edge Computing	• Menor latência na transmissão de mensagens; • Menor tráfego de mensagens em rede; • Foco em segurança de dados;	• Possíveis altos custos iniciais; • Capacidade computacional limitada; • Dificuldades de execução de modelos de machine learning; • Dificuldades em escalabilidade;
Cloud Computing	• Maior poder computacional disponível; • Escalabilidade; • Possível menor custo inicial;	• Alta latência; • Maior risco em segurança de dados; • Maior quantidade de pacotes enviados à rede;

Fonte: Adaptado de Andriulo et al. (2024).

A tabela 4 explicita que tanto Cloud Computing quanto Edge Computing trazem prós e contras em relação à sua implementação em projetos. Cada projeto tem uma necessidade a ser suprida, e não se atentar a nuances do processo de modelagem sistêmica pode acarretar a absorção de desvantagens com as quais o projeto não está preparado para lidar.

2.2.4 Restrições Regulatórias

Ao redor do mundo, protocolos de transmissão que utilizam ondas de rádio como meio de propagação de sinal têm seu funcionamento regulado por órgãos competentes pela homologação de dispositivos de comunicação. No Brasil, a ANATEL (Agência Nacional de Telecomunicações) é a responsável por regular, fiscalizar e homologar dispositivos com o foco de estabelecer redes de comunicação.

O AU915 é a restrição imposta pela ANATEL no Ato nº 14.448, estabelecida em 4 de dezembro de 2017 (ANATEL, 2017), em que se adota o padrão australiano de radiocomunicação. Visto que o Brasil adotou o padrão americano de distribuição de canais, o Industrial, Scientific and Medical (ISM), o AU915 foi escolhido por conta da já existente implantação de infraestrutura de rádio que ocupava parcialmente as faixas abaixo de 915 MHz; portanto, o padrão americano (US915), que funciona em uma faixa de frequência entre 902 e 928 MHz, tornou-se inadequado para implantação em território brasileiro.

O ISM foi desenvolvido em Atlanta em 1947, elaborado pela FCC (Federal Communications Commission), com o objetivo de delimitar internacionalmente os espectros de frequências de rádio para as mais diversas finalidades. Em 1985, a FCC autorizou o uso livre de espectros de rádio em bandas ISM sem a necessidade de licenciamento para utilização em determinados espectros de frequência.

Entre as regulações implementadas pelos mais diversos países ao redor do mundo, dois termos ganham grande relevância. O *duty cycle* é a relação entre o tempo em que um dispositivo ocupa um canal de rádio e o tempo total de observação. Já o *dwell time* é o tempo máximo de ocupação contínua de uma frequência por transmissão (ADAM, 2022).

Tendo o AU915 operando entre as faixas de frequência de 915 e 928 MHz, a norma brasileira não impõe restrição de duty cycle; em seu lugar, o Ato nº 14.448 estabelece que, para sistemas de salto em frequência operando nas faixas de 902–907,5 MHz e 915–928 MHz com largura de faixa de canal inferior a 250 kHz, caso do LoRa com 125 kHz, o tempo médio de ocupação de qualquer radiofrequência não deve ser superior a 0,4 segundos em um intervalo de 14 segundos, com uso mínimo de 35 canais de salto.

O AU915 utiliza 64 canais de uplink e 8 canais de downlink que se distribuem entre os espectros de frequência delimitados pela restrição regulatória. No caso de uplink, como mostrado pela tabela 5, os canais são numerados entre 0 e 63 e distribuídos com espaçamentos de 200 kHz, iniciando em 915,2 MHz até 927,8 MHz. Já no caso de downlink, como mostrado na tabela 6, os canais são numerados de 0 a 7 e distribuídos entre 923,3 e 927,5 MHz com espaçamentos de 500 kHz (LoRa Alliance Regional Parameters Workgroup, 2025).

Tabela 5 – Uplink: Canais de Frequência

Canal	**Frequência Inicial (MHz)**
0	915,2
1	915,4
2	915,6
...	...
63	927,8

Tabela 6 – Downlink: Canais de Frequência

Canal	**Frequência Inicial (MHz)**
0	923,3
1	923,8
2	924,3
...	...
7	927,5

O termo salto de frequência especificado pelo AU915 trata-se de um padrão de envio de pacotes em canais de frequência. Na tecnologia LoRa, adotam-se dois padrões de envio:

o Chirp Spread Spectrum (CSS), no qual o uplink é transmitido em um canal escolhido de forma pseudoaleatória dentro dos limites regulatórios especificados, em que cada pacote é enviado de forma atomizada, e, em downlink, a mensagem é enviada no mesmo canal em que o uplink foi recebido (Semtech Corporation, 2024a); e o Long Range Frequency Hopping Spread Spectrum (LR-FHSS), que tem por objetivo ampliar a capacidade de escalonamento do sistema, sendo aplicável apenas em uplink, funcionando de forma a segmentar a mensagem em diversos pacotes e distribuí-los em diversos canais, assim prevenindo a sobrecarga de canal (LoRa Alliance Regional Parameters Workgroup, 2025).

Outro importante ponto para adequação aos limites regulatórios brasileiros é a configuração de Data Rate (DR) e, por consequência, do SF. Como explicado pela LoRa Alliance Regional Parameters Workgroup (2025), DR é um indicador de velocidade de transmissão de dados em pacote, assim como o SF, organizado em classes que vão de 0 a 15, em que, quanto menor a classe, menor é a taxa de transmissão de dados em bit por requisição. Este indicador está extremamente vinculado ao SF, de forma que quanto menor a classe de SF, maior é a classe de DR, evidenciando, assim, menor tempo de pacote no ar, e, ao contrário, quanto maior a classe SF, menor é a classe DR. As tabelas 7 e 8 demonstram como cada classe de DR impacta no funcionamento de um sistema baseado em tecnologia LoRa.

Tabela 7 – Taxas de transmissão Uplink e configurações LoRaWAN.

Uplink Data Rate	**Configuration**	**Indicative Physical Bit Rate [bit/sec]**
0	LoRa: SF12 / 125 kHz	250
1	LoRa: SF11 / 125 kHz	440
2	LoRa: SF10 / 125 kHz	980
3	LoRa: SF9 / 125 kHz	1760
4	LoRa: SF8 / 125 kHz	3125
5	LoRa: SF7 / 125 kHz	5470
6	LoRa: SF8 / 500 kHz	12500
7	LR-FHSS CR1/3: 1.523 MHz BW	162
8	RFU	
9	LoRa: SF6 / 125 kHz	9375
10	LoRa: SF5 / 125 kHz	15625
11-14	RFU	
15	Defined in [TS001][3]	

Fonte: Adaptado de LoRa Alliance, (LoRa Alliance Regional Parameters Workgroup, 2025).

Tabela 8 – Parâmetros de Downlink Data Rate

Downlink Data Rate	**Configuration**	**Indicative Physical Bit Rate [bit/sec]**
0	LoRa: SF5 / 500 kHz	62500
1-7	RFU	
8	LoRa: SF12 / 500 kHz	980
9	LoRa: SF11 / 500 kHz	1760
10	LoRa: SF10 / 500 kHz	3900
11	LoRa: SF9 / 500 kHz	7000
12	LoRa: SF8 / 500 kHz	12500
13	LoRa: SF7 / 500 kHz	21900
14	LoRa: SF6 / 500 kHz	37500
15	Defined in [TS001][3]	

Fonte: Adaptado de LoRa Alliance, (LoRa Alliance Regional Parameters Workgroup, 2025).

O DR impacta também na configuração de recebimento de mensagens. Como explicado anteriormente, quando o dispositivo final estiver em classe A e enviar uma requisição uplink, o servidor de rede, ao receber a mensagem, devolverá uma requisição downlink. Essa última requisição será lida em uma janela de tempo específica, e sob um data rate especificado em uma tabela. A tabela 9 especifica as possíveis configurações da janela de recebimento (chamada de RX1), que entram em conformidade com o AU915.

Tabela 9 – Downlink RX1 Data Rate Mapping

Uplink Data Rate	**Downlink Data Rate**					
`RX1DROffset`	**0**	**1**	**2**	**3**	**4**	**5**
DR0	DR8	DR8	DR8	DR8	DR8	DR8
DR1	DR9	DR8	DR8	DR8	DR8	DR8
DR2	DR10	DR9	DR8	DR8	DR8	DR8
DR3	DR11	DR10	DR9	DR8	DR8	DR8
DR4	DR12	DR11	DR10	DR9	DR8	DR8
DR5	DR13	DR12	DR11	DR10	DR9	DR8
DR6	DR13	DR13	DR12	DR11	DR10	DR9
DR7	DR9	DR8	DR8	DR8	DR8	DR8
DR9	DR14	DR13	DR12	DR11	DR10	DR9
DR10	DR0	DR14	DR13	DR12	DR11	DR10

Fonte: Adaptado de LoRa Alliance, (LoRa Alliance Regional Parameters Workgroup, 2025).

Outro fator importante a determinar dentro de um sistema LoRa é o Effective Isotropic Radiated Power (EIRP), que é o valor em dBm que representa a potência do sinal de rádio emitido pelo hardware. O valor máximo permitido pela regulação AU915 é de +30 dBm. O EIRP é determinado pela fórmula 2.1, em que o parâmetro *TXPower* é configurável via software no dispositivo final.

$$\text{EIRP} = \text{MAX EIRP} - 2 \times \text{TXPower} \tag{2.1}$$

2.2.5 Inteligência Artificial

2.2.5.1 Machine Learning

Segundo Vilela (2021), Machine Learning pode ser definida como um ramo da Inteligência Artificial (IA) responsável por capacitar computadores a simular aprendizado com base em processamento de dados. Essa técnica está em ascensão atualmente, sendo amplamente aplicada em softwares que têm por objetivo a identificação de padrões, como é o caso do OCR, detecção de phishing em e-mails, detecção de uso fraudulento de cartões de crédito, entre outras aplicações.

Tal subconjunto tem por característica a distinção de métodos de aprendizagem, tendo como os mais difundidos os métodos supervisionado, não supervisionado e semissupervisionado.

2.2.5.1.1 Aprendizado Supervisionado

Neste método de aprendizagem, o objetivo é ensinar ao modelo de IA, através de objetos previamente rotulados, a identificar características de modo a classificar novos objetos (VILELA, 2021). Entre os algoritmos mais importantes para a aplicação deste tipo de método de treinamento estão:

1. k-Nearest Neighbours;
2. Regressão Linear;
3. Máquina de Vetores de Suporte (SVM);
4. Árvore de Decisão e Floresta Aleatória;
5. Redes Neurais;

Observação: estes algoritmos não necessariamente são concorrentes; portanto, em um único modelo, pode haver implementação de um ou mais dos algoritmos citados (VILELA, 2021).

2.2.5.2 Deep Learning

Deep Learning, ou aprendizado profundo, é uma técnica que se encontra em um subcampo do Machine Learning, cujo desenvolvimento foi pautado na simulação do processo de aprendizagem humana. Nesse caso, utiliza-se como base o algoritmo de redes neurais, construindo estruturas conectadas de forma a emular o comportamento do cérebro humano (JESUS; COQUEIRO, 2023).

2.2.5.3 Redes Neurais

Como apresentado por Jesus e Coqueiro (2023), redes neurais são estruturas baseadas em grafos, representadas em camadas; cada camada é composta por nós, denominados neurônios, e arestas, denominadas sinapses. A estrutura básica de uma rede neural possui três camadas: entrada, camada intermediária e saída, que são, respectivamente, responsáveis por executar as funções de receber os dados externos, processar os dados e entregar o resultado.

A técnica de redes neurais apresenta derivações amplamente utilizadas como alicerce no desenvolvimento de sistemas baseados em Deep Learning.

2.2.5.3.1 Redes Neurais Convolucionais

Atualmente, as redes neurais convolucionais são amplamente aplicadas em processamento de dados não estruturados, como imagens, vídeos e áudios. Tal técnica tem como

característica o processamento de pequenos trechos de dados por vez, ao contrário de outras técnicas que tentam realizar o processamento de forma atômica (JESUS; COQUEIRO, 2023).

Como apresentado por Atika et al. (2022), o desenvolvimento de uma Convolutional Neural Network (CNN) inicia-se pela definição da arquitetura em implementação. Tal técnica abrange uma vasta quantidade de arquiteturas que foram desenvolvidas para auxiliar e alcançar melhores resultados para determinados requisitos do software.

2.2.5.3.2 Camadas que Constituem uma CNN

Uma CNN é constituída por três principais camadas: camada de entrada de dados, camada de saída, também denominada camada densa, na qual cada um de seus neurônios está conectado à camada anterior, e diversas outras camadas intermediárias, denominadas por alguns autores camadas ocultas (AYENI, 2022).

As camadas intermediárias de uma CNN apresentam comportamento de aprofundamento em reconhecimento de abstrações a cada camada sobreposta, de tal forma que as camadas iniciais são responsáveis por identificar traços, contornos, linhas etc., enquanto as camadas finais possuem a responsabilidade de identificar objetos, rostos e valores, por exemplo. Tais camadas são desenvolvidas com a intercalação de camadas de convolução e pooling (agrupamento), de forma que cada entrada de uma camada é a saída da camada anterior.

2.2.5.3.3 Camada Convolucional

Como Ayeni (2022) explica, a camada convolucional é a camada responsável por processar imagens de forma a encontrar padrões ao aplicar um filtro (kernel/neurônio) a cada trecho da imagem de entrada, denominado campo perceptivo. O neurônio é responsável por aplicar operações de multiplicação sobre o campo perceptivo, gerando um único valor para cada trecho de imagem processado, e, posteriormente, os valores calculados pelos neurônios são armazenados em uma estrutura de três dimensões (AYENI, 2022).

A aplicação de escala de cinza sobre uma imagem antes de submetê-la ao modelo de CNN justifica-se dado que, ao reduzir a complexidade de processamento de cores de uma imagem, que comumente dispõe do padrão Red, Green, Blue (RGB), de três canais de dados, impacta-se diretamente sobre a percepção de profundidade do modelo (AYENI, 2022).

2.2.5.3.4 Camada de Pooling

Segundo Ayeni (2022), a camada de pooling possui a responsabilidade de filtrar características predominantes encontradas na camada de convolução. Tal camada possui a

importantíssima função de otimizar processamento, descartando dados menos significativos e mitigando o fenômeno de overfitting. As camadas de pooling possuem diversas derivações, que são escolhidas e implementadas a fim de otimizar resultados alcançados pelo modelo, mas a derivação mais aplicada sobre CNNs é a Max Pooling. As camadas de Pooling possuem por característica uma dimensão menor em relação às camadas convolucionais, normalmente representada por uma matriz dois por dois.

2.2.5.3.5 Camada Totalmente Conectada

Como Ayeni (2022) explica, a camada denominada Fully-Connected (Totalmente Conectada) possui a função de interpretar abstrações mais complexas da imagem e classificá-las. Essa camada possui todos os seus parâmetros conectados com os parâmetros da camada anterior, corriqueiramente resultando em um número de nós de saída igual à quantidade de classes de classificação.

2.2.5.3.6 Arquitetura U-Net

Dado o objetivo da implementação de CNN neste trabalho, destaca-se a arquitetura U-Net.

Como Atika et al. (2022) explicam, a arquitetura U-Net tem por objetivo a definição de bordas dentro de imagens, sendo amplamente utilizada na biomedicina com o foco de delimitar estruturas presentes em imagens; tal característica é explorada a fim de definir regiões de interesse dentro de uma imagem.

A arquitetura U-Net é caracterizada pela presença de três etapas de processamento: Contração, Gargalo e Expansão. A camada de contração é composta por vários blocos, nos quais cada bloco recebe uma entrada e aplica uma camada de convolução seguida por uma camada de operação de max-pooling; essas camadas são matrizes que, respectivamente, apresentam a estrutura 3x3 e 2x2.

Com adendo, as camadas que constroem a arquitetura U-Net utilizam a função de ativação ReLU apresentada na equação 2.2.

$$f(x) = \text{ReLU}(x) = \max(0, x) = \begin{cases} x, & \text{se } x > 0 \\ 0, & \text{se } x \leq 0 \end{cases} \tag{2.2}$$

2.2.5.4 Quantização e QAT

Quantização é um método de simplificação dos parâmetros de um modelo de Redes Neurais Artificiais (RNA). Como Ferreira (2022) explica, a aplicação de tal técnica traz como benefício a redução do tamanho de modelos, viabilizando a utilização em equipamentos de baixo poder computacional, além do aumento de velocidade de inferência

e simplificação de cálculos realizados pelo processador, frente a um modelo que, na maioria dos casos, possui seus parâmetros representados em pontos flutuantes de 32 bits.

A técnica Quantization-Aware Training (QAT), com foco em transformação de parâmetros para inteiros de 8 bits, simula a perda de precisão da conversão de FP32 para INT8 durante o treinamento, permitindo que os pesos da rede se adaptem e mitiguem a degradação de acurácia. Em sistemas de OCR para medidores, modelos quantizados alcançam tamanhos da ordem de centenas de kB e inferência em subsegundo em hardware embarcado (ADEMOLA; PETLENKOV; LEIER, 2023; JAWAS; INDRIANTO, 2018).

2.2.5.5 OCR - Fundamentos e Escopo

O OCR é um subcampo da Visão Computacional e da Inteligência Artificial dedicado à conversão de imagens contendo texto (impresso, manuscrito ou gravado) em dados legíveis por máquina (CHEN et al., 2021). Originalmente voltado à digitalização de documentos, o escopo foi ampliado pelo *Deep Learning* para aplicações industriais e de IoT (JAWAS; INDRIANTO, 2018).

2.2.5.5.1 Pipeline Tradicional

Um sistema clássico de OCR opera em etapas interdependentes (CHEN et al., 2021):

1. **Aquisição e pré-processamento**: melhoria de contraste, correção de inclinação (*deskewing*), remoção de ruído e binarização; em dispositivos embarcados, etapas de segmentação semântica podem isolar a Região de Interesse (ROI) antes do reconhecimento.
2. **Localização e segmentação de texto**: identificação das regiões de texto.
3. **Reconhecimento de caracteres**: classificação dos segmentos ou da sequência completa.
4. **Pós-processamento**: dicionários, correção ortográfica ou verificação sintática para mitigar erros residuais.

2.2.5.5.2 Evolução Tecnológica: dos Métodos Heurísticos ao Deep Learning

A literatura descreve três gerações principais (CHEN et al., 2021):

Primeira geração (Template Matching). Sobreposição pixel a pixel com gabaritos estáticos; alta vulnerabilidade a variações de escala, rotação e fontes.

Segunda geração (Características manuais + classificadores clássicos). Uso de descritores como HOG e SIFT, combinados com SVM ou MLP; dependência de *feature engineering*.

Terceira geração (End-to-End Deep Learning). Elimina a segmentação explícita de caracteres; modelos *end-to-end* aprendem simultaneamente representações visuais e dependência contextual sequencial (SHI; BAI; YAO, 2017).

2.2.5.6 Arquitetura CRNN e CTC

A arquitetura Convolutional Recurrent Neural Network (CRNN) é amplamente utilizada em aplicações que exigem inferência de classes em sequência, pois combina um extrator convolucional (CNN) a fim de obter representações visuais, uma camada recorrente (Recurrent Neural Network (RNN)), com o objetivo de modelar dependências contextuais ao longo do eixo horizontal, e a função de perda Connectionist Temporal Classification (CTC), com a finalidade de alinhar as previsões da rede à sequência de rótulos sem a necessidade de segmentação explícita dos caracteres (SHI; BAI; YAO, 2017).

A técnica CTC resolve o problema central de sequências de comprimento variável: em geral, não se sabe onde cada caractere começa e termina na imagem, e o número de *frames* produzidos pela CNN é maior do que o número de caracteres da palavra ou número a ser reconhecido (GRAVES et al., 2006). Para lidar com isso, a técnica CTC introduz dois mecanismos fundamentais: um *token* oculto de espaçamento (*blank*) e uma função de colapso que mapeia a sequência de previsões da rede para o rótulo final (GRAVES et al., 2006; HANNUN, 2017).

O *token blank* e o colapso de repetições. A cada passo de tempo, a rede produz uma distribuição de probabilidade sobre o alfabeto acrescido do símbolo especial *blank* (ϵ). O *blank* representa a ausência de emissão de caractere naquele instante, funcionando como um separador entre caracteres idênticos adjacentes (GRAVES et al., 2006). Após a rede produzir a sequência completa de previsões, aplica-se uma função de colapso $\mathcal{B}$ que (i) remove caracteres repetidos consecutivos e (ii) remove os *blanks* (HANNUN, 2017). Por exemplo, a sequência de caminho $--h--e--l--l--o--$ colapsa para "hello"; sem o *blank*, as repetições de "l" seriam indistinguíveis de um único "l" (HANNUN, 2017).

Marginalização de alinhamentos. O treinamento da CTC não exige um alinhamento predefinido entre os *frames* e os caracteres. Em vez disso, a função de perda calcula a probabilidade da sequência de rótulos correta como a soma das probabilidades de todos os caminhos de alinhamento válidos que, após o colapso, produzem aquele rótulo (GRAVES et al., 2006). Essa marginalização é feita de forma eficiente pelo algoritmo *forward-backward*, que explora a estrutura do problema para evitar a enumeração explícita

de todos os caminhos, que seria computacionalmente inviável (GRAVES et al., 2006; HANNUN, 2017). Assim, a rede pode ser treinada diretamente com pares (imagem, transcrição), sem anotações de posição caractere a caractere.

Inferência. No momento da inferência, a rede produz, para cada passo de tempo, a classe mais provável (ou uma distribuição sobre as classes). A sequência final é obtida pelo colapso das previsões, opcionalmente combinado com busca em feixe (*beam search*) para explorar múltiplos alinhamentos e melhorar a acurácia (HANNUN, 2017). O artigo de Hannun (2017) apresenta uma explicação visual detalhada desse processo, incluindo exemplos passo a passo de como o *blank* e o colapso atuam em sequências reais (HANNUN, 2017).

Por que a CTC é adequada ao OCR. Em OCR de palavras, números de medidores ou placas, o número de caracteres varia e não há garantia de que cada caractere ocupe exatamente um número fixo de *frames* na saída da CNN. A CTC elimina a necessidade de segmentação manual e permite que a CRNN seja treinada de ponta a ponta com sequências de comprimentos diferentes, mantendo a coerência entre as previsões vizinhas e evitando o colapso de repetições idênticas (SHI; BAI; YAO, 2017; GRAVES et al., 2006).

2.3 Trabalhos correlatos

Nesta seção, analisam-se pesquisas que utilizam IoT e Visão Computacional para a digitalização de medidores de consumo, como as soluções de computação de borda propostas por Vilela (2021) e Bravo, Javier e Tolentino (2025), além de arquiteturas de sensores inteligentes exploradas por Tedjojuwono e Jahja (2024). O objetivo é contextualizar as escolhas arquiteturais deste TCC, comparando modelos de processamento (borda vs nuvem) e protocolos de comunicação sem fio. A revisão fundamenta o estado da técnica e destaca os diferenciais desta proposta em termos de infraestrutura de dados e eficiência energética.

2.3.1 Trabalho 1: Solução IoT para Digitalização de Medidores de Consumo por Visão Computacional e MicroML

Vilela (2021) abordou o tema de soluções IoT para Medidores de Consumo. Para resolvê-lo, foi desenvolvido um sistema utilizando microprocessadores ESP32, baseado no método de Edge-Computing (Computação em Borda). O autor desenvolveu um software próprio, otimizado para microprocessadores, focado em OCR, extraindo os dados, transmitindo-os via rede LoRaWan e armazenando-os localmente; posteriormente, os dados são apresentados em um simples dashboard apresentando o consumo extraído pelo sistema até o momento.

A metodologia utilizada foi a pesquisa experimental, na qual houve o desenvolvimento de um sistema que supre a necessidade de extração de dados de maneira digital.

Os resultados mostraram que o desenvolvimento deste tipo de ferramenta é totalmente viável e, em suma, o experimento foi bem-sucedido. No entanto, a solução apresenta limitações, principalmente no que tange ao desenvolvimento do dataset, no qual não foi implementado tratamento adequado ao enviesamento dos dados. Também existe uma carência de métricas para medição de consumo energético e de processamento pelo sistema.

O presente trabalho diferencia-se por aplicar uma comparação entre uma arquitetura clássica de Edge vs Cloud, e um ponto que atacamos mais profundamente é a apresentação de métricas importantíssimas no desenvolvimento de um sistema IoT além da acurácia de modelo, por exemplo, as métricas de consumo energético e impactos em manutenção por decisões tomadas.

2.3.2 Trabalho 2: Sistema de Gerenciamento Inteligente de Água Utilizando Sensores Baseados em IoT

Tedjojuwono e Jahja (2024) abordaram o tema de sistemas inteligentes para o manejo de recursos hídricos em áreas residenciais. Para resolvê-lo, os autores propuseram o desenvolvimento de um framework que substitui medidores mecânicos por sensores de fluxo eletrônicos integrados a uma arquitetura IoT. O sistema utiliza prototipagem com Arduino Uno e sensores de efeito Hall (YF-S201) para coletar dados de vazão em tempo real, enviando as informações via módulo 3G/GPRS para um servidor de banco de dados centralizado. Os dados processados alimentam uma aplicação web que permite o monitoramento do consumo, faturamento automatizado e a detecção precoce de anomalias na distribuição.

A metodologia utilizada seguiu os princípios do Design Thinking, incluindo uma fase qualitativa de coleta de requisitos através de entrevistas com usuários e a criação de mapas de empatia, seguida pelo desenvolvimento do protótipo e avaliação de usabilidade através da escala SUS (System Usability Scale).

Os resultados mostraram que a solução é viável e intuitiva, obtendo uma pontuação média de 72 na escala SUS, o que indica uma boa aceitação pelos usuários. No entanto, o trabalho aponta limitações na abrangência dos dados, focando primariamente na taxa de fluxo, e destaca a necessidade de integrar mais tipos de sensores (como pressão e qualidade da água) para análises de Big Data mais robustas. Além disso, a precisão total do sistema de previsão depende de um volume maior de dados históricos que ainda precisam ser coletados.

O presente trabalho diferencia-se por focar na infraestrutura de comunicação LoRaWan, visando uma maior eficiência energética e alcance em comparação ao GPRS/3G utilizado pelos autores, além de explorar a integração direta com medidores analógicos já existentes

através de telemetria, em vez da substituição completa do hardware de medição.

2.3.3 Trabalho 3: Rede de Sensores Sem Fio Habilitada para LoRa para Leitura e Faturamento de Consumo de Água Usando Reconhecimento Óptico de Caracteres

Bravo, Javier e Tolentino (2025) desenvolveram um sistema automatizado para leitura de hidrômetros analógicos utilizando uma combinação de tecnologias de baixo custo e comunicação de longo alcance. O objetivo central foi mitigar erros humanos e atrasos operacionais comuns em leituras manuais.

A metodologia consistiu na integração de um módulo ESP32-CAM para captura de imagens dos medidores e um algoritmo de OCR para a extração digital dos dados de consumo no próprio dispositivo. Para a transmissão, utilizou-se a tecnologia LoRa (módulo Ra-02), operando em uma topologia de rede que inclui repetidores para estender o alcance e um gateway central para envio dos dados à nuvem. O sistema também implementou estratégias de gerenciamento de energia através de ciclos de *deep sleep* programados para aumentar a vida útil da bateria.

Os resultados apontaram uma precisão de 99,71% no reconhecimento dos dígitos e um alcance de transmissão estável de até 1070 metros em condições de campo aberto. Os autores observaram que medidores mais antigos ou obstruídos podem elevar o tempo de processamento do OCR.

O presente trabalho diferencia-se da abordagem de Bravo, Javier e Tolentino (2025) ao deslocar a carga computacional do OCR do dispositivo final para a nuvem. Enquanto o trabalho correlato executa o processamento localmente no ESP32-CAM, esta pesquisa foca na robustez de um pipeline de processamento remoto. Isso permite a utilização de modelos de visão computacional mais complexos e precisos, que excederiam a capacidade de memória e processamento do hardware local, além de centralizar a lógica de extração de dados para facilitar manutenções e atualizações do algoritmo de IA sem a necessidade de novos firmwares nos sensores. Esta abordagem também visa mitigar as dificuldades de processamento em medidores antigos ou obstruídos, um desafio observado na implementação local de Bravo, Javier e Tolentino (2025).

Utilizaremos esse trabalho como referência de borda para realizar uma comparação com a abordagem de processamento em nuvem, contribuindo para a discussão sobre o trade-off entre eficiência energética e precisão em sistemas de telemetria de baixo custo.

3 Desenvolvimento / Implementação / Experimentos

3.1 Metodologia da pesquisa

Para avaliar a eficácia do sistema de telemetria proposto e garantir a objetividade dos resultados, serão adotados indicadores quantitativos divididos em três dimensões críticas: desempenho de rede, precisão de visão computacional, eficiência energética e acurácia preditiva.

3.1.1 Desempenho da Rede de Comunicação

A robustez da transmissão via LoRaWan será quantificada através da Packet Delivery Ratio (PDR). Conforme a metodologia de Bravo, Javier e Tolentino (2025), o PDR é definido pela razão entre o número de pacotes recebidos pelo *gateway* e o número de pacotes enviados pelo nó sensor:

$$PDR = \left(\frac{\text{Pacotes Recebidos}}{\text{Pacotes Enviados}} \right) \times 100 \tag{3.1}$$

Além do PDR, será medida a latência de ponta a ponta, compreendendo o tempo decorrido desde o disparo da captura da imagem no ESP32 até a disponibilidade do dado processado no *dashboard*.

3.1.2 Acurácia da Visão Computacional (OCR)

A validação do algoritmo de OCR, responsável pela extração dos dígitos dos medidores, será realizada sob diferentes condições de iluminação e ângulos de captura, visando simular cenários reais de instalação.

Conforme discutido por Barkat (2024), a eficácia de modelos de *Deep Learning* aplicados ao monitoramento deve ser medida pela sua capacidade de generalização. Para este trabalho, a métrica principal será a Acurácia de Leitura (Acc_{ocr}), definida pela razão entre as predições que coincidem exatamente com o valor real (verdade de campo) e o total de amostras testadas:

$$Acc_{ocr} = \frac{VP + VN}{VP + VN + FP + FN} \tag{3.2}$$

Em que VP, VN, FP e FN representam, respectivamente, os Verdadeiros Positivos, Verdadeiros Negativos, Falsos Positivos e Falsos Negativos obtidos através da Matriz de Confusão. Esta abordagem quantitativa permite identificar se erros de leitura estão

associados a fatores externos, como reflexos na cúpula de vidro do medidor ou distorções de perspectiva.

3.1.3 Autonomia Energética

A eficiência do hardware será validada através da medição do consumo de corrente em diferentes estados de operação (*Deep Sleep*, captura de imagem e transmissão). A autonomia estimada (A) em dias será calculada pela relação entre a capacidade da bateria (C_{bat}) e o consumo médio diário ($I_{médio}$):

$$A = \frac{C_{bat}}{I_{médio} \times 24} \tag{3.3}$$

3.2 Detalhes da implementação

Explique a modelagem e a arquitetura da solução (diagramas UML, blocos ou fluxogramas que mostrem como os módulos se relacionam e atendem ao problema), as escolhas tecnológicas, as estruturas de dados e as integrações. Quando esclarecerem decisões de pesquisa, inclua trechos de código relevantes ou pseudoexemplos. Caso o trabalho envolva dados, descreva também como eles foram coletados (logs, sensores, APIs), armazenados e preparados (limpeza, normalização, anonimização).

Figura 7 – Exemplo de inserção de figura — substitua pelo diagrama da arquitetura da sua solução.



Fonte: Elaborado pelo autor (2025)

Toda figura deve ser numerada, ter legenda (`\caption`) e indicação de fonte, além de ser citada no texto — por exemplo, a Figura 7. As figuras com legenda aparecem automaticamente na *Lista de ilustrações*, nos elementos pré-textuais.

3.3 Experimentos e cenário de testes (opcional)

Esta seção é **opcional** e deve ser incluída quando o trabalho prevê avaliação experimental. Descreva os cenários planejados, os parâmetros testados e por que cada experimento

está alinhado aos objetivos. Liste os conjuntos de dados, as variações e o número de repetições.

3.4 Resultados e análises

Apresente os resultados com tabelas, gráficos e figuras e, sobretudo, **analise-os** à luz da revisão bibliográfica e da hipótese — resultados devem ser analisados, não apenas exibidos. Diferencie:

- **Figura:** imagens, diagramas conceituais ou arquiteturais que ilustram estrutura ou fluxo.
- **Gráfico:** plot de dados (linhas, barras, boxplots) que compara métricas obtidas.

Exemplo de tabela:

Tabela 10 – Comparação de métricas reportadas

Método	Acurácia	Tempo médio (ms)
Proposta	92%	180
Baseline	88%	220

Fonte: Elaborado pelo autor (2025)

Ao inserir um gráfico (por exemplo `assets/figures/desempenho.png`), use — lembrando que, pela ABNT, o `\caption` (título) vem **acima** da imagem e a fonte (`\legend`) vem **abaixo**:

```
\begin{figure}[htb]
  \centering
  \caption{Gráfico de comparação das métricas de acurácia.}
  \label{fig:grafico-desempenho}
  \includegraphics[width=0.8\textwidth]{assets/figures/desempenho.png}
  \legend{Fonte: Elaborado pelo autor (2025)}
\end{figure}
```

Na sequência, faça a **análise crítica e comparação**, discutindo as descobertas em relação aos trabalhos correlatos e evidenciando ganhos e perdas; por fim, na **discussão**, relacione os resultados aos objetivos e à hipótese, explicitando se o critério de sucesso foi atingido.

O desenvolvimento só é pesquisa se estiver claramente ligado ao problema e à metodologia definida.

4 Conclusão

4.1 Retomada do problema e dos objetivos

Retome o problema e destaque o que foi atingido.

4.2 Contribuições para a Computação

Explique o que a pesquisa trouxe de novo.

4.3 Limitações e trabalhos futuros

Liste limites e sugira próximos passos coerentes.

Observações importantes

Para graduação, Wazlawick aceita trabalhos aplicados desde que:

- O problema seja preciso;
- A solução esteja fundamentada;
- Haja análise crítica;
- Não seja apenas entrega funcional.

Apresentação oral (banca)

Além do documento escrito, o TCC2 é avaliado por uma **apresentação oral** final perante a banca. Um template pronto em `Beamer` está disponível no arquivo `apresentacao_tcc2.tex`, na mesma pasta deste documento.

Regras da apresentação do TCC2

- **Duração: 30 minutos.** Cronometre os ensaios; ultrapassar o tempo é penalizado. A arguição da banca ($\approx$ 5 min) ocorre após a apresentação, separada desse total.
- **Cubra o trabalho completo**, seguindo a estrutura do documento escrito: introdução e problema, objetivos e método, desenvolvimento, **resultados e análise** e conclusão/contribuições.
- **Dê peso aos resultados:** grande parte do tempo deve ser dedicada a apresentar e **analisar criticamente** os resultados, não apenas descrevê-los.
- **Ritmo:** cerca de 1 a 1,5 minuto por slide, totalizando aproximadamente 20 a 26 slides de conteúdo.
- **Logo do SENAC:** grande no primeiro slide (capa) e pequena no canto superior direito dos demais slides — já configurado no template.
- **Demonstração:** se houver demo ao vivo, tenha um plano B com capturas de tela ou vídeo curto.
- **Slides de apoio (backup):** inclua slides extras após o "Obrigado" com detalhes técnicos, trechos de código e tabelas completas para a arguição.

Distribuição de tempo sugerida (30 min): introdução/problema $\approx$ 4 min; objetivos/método $\approx$ 5 min; desenvolvimento $\approx$ 8 min; resultados/análise $\approx$ 8 min; conclusão $\approx$ 3 min; demonstração $\approx$ 2 min.

Glossário

Cloud Computing Método de processamento em nuvem 2, 3, 10, 22, 23

Edge Computing Método de processamento local 2, 3, 10, 11, 22, 23

ESP32-CAM Módulo para acoplamento no microprocessador ESP32, conferindo ao dispositivo a capacidade de capturar imagens 2, 3, 11, 12, 14, 35

payload Caracteres enviados no corpo do pacote de rede 17, 21

retrofitting Técnica de modernização ou atualização de dispositivos e equipamentos 2, 3, 11, 12

Smart Metering Tecnologias para Medição Inteligente 2, 3, 11

Referências

ADAM, L. *Desenvolvimento e implantação de solução para comunicação bidirecional de longo alcance com medidores de energia elétrica*. Dissertação (Dissertação (Mestrado em Engenharia Elétrica)) — Universidade Federal de Santa Maria, Santa Maria, RS, 2022. Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em Sistemas Elétricos de Potência. 10, 24

ADEMOLA, O. A.; PETLENKOV, E.; LEIER, M. Resource-aware scene text recognition using learned features, quantization, and contour-based character extraction. *IEEE Access*, v. 11, p. 56865–56874, 2023. Revista de acesso aberto (IEEE Access). 31

AHMAD, S. et al. Comparative analysis and practical implementation of the esp32 microcontroller module for the internet of things. In: *2021 International Conference on Computing, Electronic and Electrical Engineering (ICE Cube)*. [S.l.: s.n.], 2021. p. 1–6. 19

ALVISI, S. et al. Wireless middleware solutions for smart water metering. *Sensors*, v. 19, n. 8, 2019. 11

ANATEL. *Ato nº 14.448, de 4 de dezembro de 2017. Aprova os Requisitos Técnicos para a Avaliação da Conformidade de Equipamentos de Radiocomunicação de Radiação Restrita*. 2017. Boletim de Serviço Eletrônico da Anatel, Brasília, 02 jan. 2018. Acesso em: 16/09/2026. Disponível em: <https://informacoes.anatel.gov.br/legislacao/atos-de-certificacao-de-produtos/2017/1139-ato-14448>. 23

ANDRIULO, F. C. et al. Edge computing and cloud computing for internet of things: A review. *Informatics*, MDPI, v. 11, n. 4, p. 71, 2024. Disponível em: <https://doi.org/10.3390/informatics11040071>. 11, 12, 22, 23

ATIKA, L. et al. Image segmentation for mitral regurgitation with convolutional neural network based on unet, resnet, vnet, fractalnet and segnet: A preliminary study. *Big Data and Cognitive Computing*, MDPI, v. 6, n. 4, p. 141, 2022. Disponível em: <https://doi.org/10.3390/bdcc6040141>. 29, 30

AYENI, J. A. Convolutional neural network (cnn): The architecture and applications. *Applied Journal of Physical Science*, Integrity Research Journals, v. 4, n. 4, p. 42–50, 2022. ISSN 2756-6684. 29, 30

BARKAT, S. *Smart Water Management System Using Deep Learning and IoT-Based Predictive Modeling*. Master's Thesis — Department of Computer Science, 2024. 36

BRAVO, J. K. G.; JAVIER, C. P.; TOLENTINO, V. T. Ants: Automated network tracking system for water consumption using lora technology. *FAITH Colleges*, 2025. Acesso em: 23 abr. 2026. 33, 35, 36

CHEN, X. et al. Text recognition in the wild: A survey. *ACM Computing Surveys*, v. 54, n. 2, p. 1–35, 2021. Versão de acesso aberto: arXiv:2005.03492. 31

FERREIRA, A.; CAVALCANTE, A. L. de C. Iot on an esp32: Optimization methods regarding battery life and write speed to an sd-card. *Journal of Software Engineering and Applications*, v. 13, n. 9, 2020. 19

FERREIRA, G. B. *Compressão de redes neurais artificiais com restrições de acurácia utilizando otimização multiobjetivo baseada em modelos substitutos*. 38 p. Monografia (Monografia (Bacharelado em Ciência da Computação)) — Universidade Federal de Ouro Preto, Instituto de Ciências Exatas e Biológicas, Departamento de Computação, Ouro Preto, MG, 2022. 30

Fortune Business Insights. *Smart Water Metering Market Size, Share & Industry Analysis*. [S.l.], 2025. Disponível em: <https://www.fortunebusinessinsights.com/pt/industry-reports/smart-water-metering-market-100776>. Acesso em: 24 abr. 2026. 10

GRAVES, A. et al. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks. In: *Proceedings of the 23rd International Conference on Machine Learning (ICML)*. [S.l.: s.n.], 2006. p. 369–376. PDF público: <https://www.cs.toronto.edu/~graves/icml_2006.pdf>. 32, 33

HANNUN, A. Sequence modeling with ctc. *Distill*, v. 2, n. 11, p. e8, 2017. 32, 33

JAWAS, N.; INDRIANTO. Image based automatic water meter reader. *Journal of Physics: Conference Series*, v. 953, p. 012027, 2018. Artigo de acesso aberto (IOP Conference Series). 31

JESUS, V. A. de; COQUEIRO, T. A. S. Inteligência artificial: Uma breve revisão bibliográfica de ferramentas de machine learning e deep learning na medicina. *Faculdade de Computação, Universidade Federal do Pará (UFPA)*, Castanhal, PA, Brasil, 2023. Trabalho de Conclusão / Artigo Acadêmico. 28, 29

LoRa Alliance Regional Parameters Workgroup. *LoRaWAN Regional Parameters RP002-1.0.5*. [S.l.], 2025. Authored by the Technical Committee Regional Parameters Workgroup. Editor: D. Tholl. Disponível em: <https://lora-alliance.org/>. 17, 24, 25, 26, 27

PASTóRIO, A. F. et al. Fundamentos de lorawan – teoria e prática. *Federal University of Technology of Paraná*, 2022. 15, 17, 19, 20, 21

ROBINSON, S. *StuartCAM – ESP32CAM Picture Transfers with LoRa*. 2021. Disponível em: <https://stuartsprojects.github.io/2021/11/21/StuartCAM-ESP32CAM-Picture-Transfers-with-LoRa.html>. 20

SARI, M. E. et al. Design and implementation of esp32-based iot devices. *Sinkron: Jurnal dan Penelitian Teknik Informatika*, v. 7, n. 1, 2022. 19

Semtech Corporation. *AN1200.86: LoRa and LoRaWAN*. [S.l.], 2024. Application Note Version 1.0. Disponível em: <https://www.semtech.com>. 18, 20, 21, 25

Semtech Corporation. *AN1200.87: LoRaWAN Device Classes*. [S.l.], 2024. Application Note Version 2.0. Disponível em: <https://www.semtech.com>. 15

Semtech Corporation. *AN1200.88: Sending and Receiving Messages*. [S.l.], 2024. Application Note Version 2.0. Disponível em: <https://www.semtech.com>. 16

SHI, B.; BAI, X.; YAO, C. An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 39, n. 11, p. 2298–2304, 2017. Versão de acesso aberto: arXiv:1507.05717. 32, 33

TEDJOJUWONO, S. M.; JAHJA, J. D. Smart water management system using IOT based sensors. In: *Proceedings of the 7th International Conference on Eco Engineering Development 2023 (ICEED 2023)*. [S.l.]: IOP Publishing, 2024. (IOP Conference Series: Earth and Environmental Science, 012106), p. 1–9. 10, 33, 34

UGGERI, D.; SIMEON, E. *Smart water metering: analytical model computation for an estimated costs and benefits analysis*. Dissertação (Mestrado) — Politecnico di Milano, 2020. Disponível em: <https://www.politesi.polimi.it/handle/10589/171225>. Acesso em: 20 abr. 2026. 10

VILELA, R. da S. Solução iot para digitalização de medidores de consumo por visão computacional e microml. *Universidade Federal de Campina Grande*, 2021. 10, 11, 27, 28, 33